T3: Pump-and-Dump Detection

2026-09-16 · @Someone

Мета та контекст

Пет-проєкт для портфоліо в рамках переходу з C-level/трейдингу в ML/AI Engineering. Мета — не просто навчальна вправа, а демонстраційний кейс, що напряму відповідає задачам класу Anti-Fraud & Anomaly Detection у вакансіях Data Scientist Risk Modeling в банках/fintech — виявлення нетипових патернів у ринкових даних у реальному часі.

Вихідна ідея власника проєкту: крипторинок часто маніпулюється через pump-and-dump схеми, які повторюють подібний патерн на різних тікерах. Ціль — побудувати модель, натреновану на відомих pump-подіях, яка узагальнюється на інші, не бачені моделлю тікери.

Скоуп v1

Тип задачі: класифікація, не регресія ціни — розпізнати вікно памп в процесі проти звичайного ринку.

Референсний приклад: LSKUSDT, 11 вересня 2026, Binance Futures, 1h — видима акумуляція Open Interest до цінового зриву, підтверджуючий сплеск volume delta в момент запалювання.

Горизонт спостереження: година плюс. Для класифікації пампу горизонт означає ширину вікна ознак перед подією, потребує уточнення — див. Відкриті питання.

Тікери для v1: відомі власнику проєкту пампи за останні 1-2 тижні, з урахуванням обмеження глибини історії Coinalyze API на дрібній гранулярності — див. Джерела даних. Конкретний список тікерів TBD.

Джерела даних

Coinalyze API, api.coinalyze.net/v1 — безкоштовний, потребує реєстрації та ключа на сторінці account/api-key, ліміт 40 запитів на хвилину.

Біржі для агрегації: Binance, Bybit, OKX, Aster, Hyperliquid, MEXC. MEXC додано за практикою галузевих скринерів — там часто лістяться дрібні low-cap альти, схильні до пампів.

Кожна біржа є окремим символом у Coinalyze з власним суфіксом. Агрегація по біржах, тобто сумування показників, рахується власноруч після отримання даних — API цього не робить автоматично.

Обмеження глибини історії: для інтервалів від однієї хвилини до дванадцяти годин Coinalyze зберігає приблизно 1500-2000 останніх точок, старіше видаляється щодня. На п'ятихвилинній гранулярності це приблизно тиждень назад, на годинній — орієнтовно вісімдесят днів. Для добової гранулярності обмежень немає.

Ендпоінти, що використовуються:

- open-interest-history — рівень OI
- ohlcv-history — ціна OHLC, обсяг v, buy volume bv
- funding-rate-history та predicted-funding-rate-history
- liquidation-history — ліквідації long і short окремо
- long-short-ratio-history — top trader long/short ratio

Ознаки (features)

Група	Сирі поля	Похідні ознаки
Open Interest	рівень OI	дельта за вікно, швидкість зміни за попередні N періодів
OHLCV	o h l c v bv	log-return за вікно, volume z-score, buy volume ratio bv/v
Funding Rate	фактичний і predicted	рівень, дельта, розбіжність predicted проти факту
Ліквідації	обсяг long і short окремо	сумарний обсяг за вікно, асиметрія long проти short
Long/Short Ratio	ratio	рівень, швидкість зміни

Принцип нормалізації, критичний для узагальнення на інші тікери: усі ознаки мають бути відносними до власної історії тікера — z-score, ratio, відсоток зміни, а не абсолютними значеннями. Інакше модель, натренована на одному тікері, не перенесеться на тікер з іншим масштабом ліквідності.

Розмітка класів (labeling)

Формат розмітки: CSV-файл, який заповнюється вручну — по одному рядку на памп, з колонками symbol, start_ts, end_ts, pattern_type, notes. З цих меж код сам розставляє мітки по всіх рядках датасету: рядки всередині вікна отримують клас 1, поза ним клас 0.

Усі timestamp у UTC. Біржові API повертають час в UTC, TradingView показує локальний — неузгодженість тут найпоширеніше джерело зіпсованої розмітки.

Критерій початку: момент, коли OI починає стійко зростати над своїм звичайним рівнем. Прив'язка саме до OI, а не до ціни, але без вимоги довгої передфази — приклад MYXUSDT показує, що акумуляція може бути майже відсутньою.

Критерій кінця: різкий обвал OI після цінового піку — організатори закривають позиції. Найчіткіший і найоб'єктивніший маркер із усіх, добре видно на прикладі AKEUSDT.

Напівавтоматична розмітка на пізніших етапах: скрипт знаходить межі за правилами — початок там, де rolling z-score дельти OI перевищує поріг, кінець на першому барі після піку з різко негативною дельтою OI. Людина лише перевіряє візуально й коригує промахи. Дає консистентність, якої рука не забезпечує, і потрібна при розширенні датасету до 20-30 пампів.

Зібрані приклади для v1, потребують уточнення точних timestamp в UTC:

Тікер	Фаза акумуляції	Характер входу	Кінець події
LSKUSDT	помірна, кілька годин	вертикальна свічка	поступовий спад
GUSDT	коротка, був фальстарт раніше	різкий старт	плавний
MYXUSDT	майже відсутня	миттєвий вистріл, +85% за 2.5 год	різкий
AKEUSDT	довга, плавна	вертикаль плюс пік volume delta	різкий обвал OI

Негативний клас: спокійні періоди на тих самих чи інших тікерах без відомих pump-подій. Окремо цінні складні негативні приклади — рух ціни вгору без підтвердження по OI, як фальстарт на GUSDT перед справжнім пампом. Вони вчать модель саме тій межі, яку важко провести, на відміну від випадкових спокійних відрізків.

Дисбаланс класів: очікується сильний, оскільки pump-вікна є рідкісною подією відносно загального часу. Потребує SMOTE або зважування класів на етапі моделювання — технологія вже відома власнику проєкту з попереднього курсу, тема kNN і Naive Bayes.

Пайплайн даних

1. Збір сирих рядів по кожній парі тікер та біржа через п'ять ендпоінтів Coinalyze.
2. Агрегація по біржах — сума OI, ліквідацій тощо по Binance, Bybit, OKX, Aster, Hyperliquid.
3. Вирівнювання часових рядів по спільній сітці — merge по timestamp з округленням до обраної гранулярності, бо різні ендпоінти мають незалежні часові мітки.
4. Побудова похідних ознак — дельти, z-score, ratio.
5. Розмітка вікон на позитивний і негативний клас за ручною ідентифікацією пампів.
6. Формування фінального датасету features плюс label для моделювання.

Моделювання

Baseline: Logistic Regression, або Ridge-подібна лінійна модель на побудованих ознаках.

Порівняльна модель: LightGBM, градієнтний бустинг — перевірка, чи нелінійні залежності дають суттєвий приріст.

Дисбаланс класів: SMOTE або class weighting.

Валідація

Підхід: leave-ticker-out. Модель тренується на підмножині тікерів і пампів, тестується на інших, не бачених тікерах — перевірка гіпотези про узагальнюваність патерну.

Метрики: precision, recall, F1 — через дисбаланс класів accuracy неінформативна. Порівняння з наївним baseline обов'язкове.

Position sizing — стоп і тейк

Підхід: NATR замість фіксованих відсоткових рівнів — нормалізує розмір руху на власну волатильність тікера, той самий принцип відносності, що й для ознак.

Для кожного відомого пампу з моменту сигналу рахується MFE, максимальний рух у бажаний бік, і MAE, максимальний рух проти — обидва нормалізовані на NATR у момент сигналу.

Стоп на 75-му перцентилі MAE в одиницях NATR — при новому сигналі рівень рахується множенням поточного NATR тікера на цей коефіцієнт.

Фіксований тейк на медіані MFE відхилено: розподіл MFE для пампів право-скошений — типовий рух відносно малий, але хвіст включає рухи 100%+ за день. Фіксований тейк на медіані відрізає саме той хвіст, заради якого має сенс торгувати цю стратегію.

Замість цього: часткова фіксація плюс trailing stop на решту. Закривається частина позиції, наприклад половина, на медіанній MFE — забирає прибуток на більшості типових пампів. Решта ведеться trailing stop, який тягнеться на фіксовану відстань у NATR від поточного максимуму ціни, а не виходить на фіксованому рівні — дає позиції шанс зловити рідкісний великий рух, характерний для цієї стратегії.

Застереження: вибірка з 5-10 пампів у v1 замала для статистично надійного розподілу — це демонстрація підходу, не строга оцінка.

Real-time скринер

Мета: не лише прогноз на запит по одному тікеру, а безперервний моніторинг широкого списку тікерів з автоматичним сигналом, коли умови збігаються — фоновий процес на VPS, окремий від Streamlit-застосунку.

Двоступеневий фільтр через ліміт API: Stage 1 — дешевий широкий скан усього списку тікерів на одній біржі з мінімальним набором ознак, наприклад volume z-score і дельта OI, один-два запити на тікер.

Stage 2 — тікери, що пройшли простий поріг на Stage 1, потрапляють у вузький список кандидатів, для яких тягнеться повний набір ознак з усіх бірж і прогонка через повну модель.

Сигнал і алерт: якщо ймовірність від повної моделі перевищує поріг — запис у лог сигналів і миттєве повідомлення в Telegram-бот, щоб сигнал доходив відразу, а не після оновлення вкладки браузера.

Джерело даних для скринера, фаза: v1 на Coinalyze для швидкої валідації моделі; коли модель підтверджена, міграція на прямі API бірж окремо для production-скринера, оскільки саме масове сканування впирається в rate limit Coinalyze, а не тренування на фіксованій вибірці пампів.

Deliverable

Формат — застосунок, а не лише notebook чи скрипт. Фаза розробки: ML-пайплайн як Python-скрипти локально на машині власника проєкту, оскільки контейнер асистента не має мережевого доступу до Coinalyze чи бірж.

Фінальний формат: Streamlit-застосунок, задеплоєний на Streamlit Community Cloud — живе посилання для портфоліо чи резюме, а не лише код у репозиторії.

Хостинг: власний VPS на Vultr замість Streamlit Community Cloud — потрібен для безперервного фонового процесу скринера, який має працювати 24/7, а не лише коли хтось відкрив вкладку. Docker-контейнер, nginx як reverse proxy, HTTPS через Caddy або Certbot.

Frontend: два екрани — Прогноз (вибір тікера, метрик-картки з ймовірністю та ознаками, статистично розраховані рівні стопа й тейка з розділу Position sizing, ціновий графік з підсвіченою зоною ризику над панеллю ймовірності) і Скринер (watchlist з статусами Спокійно/Кандидат/Alert, лог сигналів з позначкою відправки в Telegram).

Живий інтерактивний макет обох екранів: https://claude.ai/artifact/MAivAWzKcz2NKqPQs4JENJ — редагується прямо в браузері, точніше за статичний скріншот.

Референси та дослідження

Rush orders як ознака: кількість великих чи раптових ордерів у короткому вікні, рахується з сирих угод — конкретна ціль для майбутнього збору стакану у Фазі 2, за прикладом академічного датасету Sapienza.

La Morgia, Mei, Sassi, Stefa (2020), Pump and Dumps in the Bitcoin Era — базова робота з раннім детектуванням і датасетом rush orders: https://arxiv.org/html/2005.06610v2

SystemsLab-Sapienza, датасет і код для завантаження транзакцій Binance по відомих пампах, джерело rush-orders ознак: https://github.com/SystemsLab-Sapienza/pump-and-dump-dataset

La Morgia, Mei, Sassi, Stefa (2023), The Doge of Wall Street — розширене дослідження P&D манипуляцій: https://dl.acm.org/doi/fullHtml/10.1145/3561300

aaivu, GAF/MTF/CNN підхід до P&D детекції, ~95% precision/recall на CNN-класифікації, код і опис: https://github.com/aaivu/aaivu-pump-and-dump-detection-crypto-currencies

Альтернативний підхід на майбутнє, v2: конвертація часових рядів у зображення через Gramian Angular Field або Markov Transition Field і тренування CNN замість табличної моделі — інша дослідницька група отримала цим шляхом високу точність, але потребує значно більшої вибірки, ніж 5-10 пампів у v1.

Фаза 2 — live ордербук

Мета: bid/ask imbalance у реальному часі як додаткова ознака поруч з прогнозом моделі, за прикладом індикаторів Velo та CoinAnk. Обидва сервіси самі підключаються до live websocket бірж, готового історичного API для глибини ордербуку не існує в жодного постачальника.

Формула: imbalance = (bidDepth − askDepth) / (bidDepth + askDepth), де bidDepth і askDepth — сума обсягу на N найкращих рівнях стакану з кожного боку. Значення від −1, тільки asks, до +1, тільки bids.

Реалізація: один live-collector процес на VPS, окремий від навчального пайплайна, підключається до публічних L2 order book websocket кожної біржі зі списку. Той самий процес одночасно рахує rush orders із Референсів — обидві ознаки походять з того самого потоку сирих угод і ордербуку, тож розумно збирати їх разом, а не окремими скриптами.

Альтернатива без власного websocket-коду: платні комерційні L2-провайдери, наприклад CoinAPI.io чи платний рівень CoinAnk. Швидше стартувати, але коштує грошей і навряд чи покриває всі шість бірж зі списку одним контрактом — для портфоліо-проєкту власна реалізація виглядає переконливіше.

Використання: imbalance стає додатковою ознакою в повній моделі для тікерів, які вже пройшли Stage 1 скринера, і окремою колонкою в таблиці watchlist на екрані Скринер.

Відкриті питання

Вирішено: момент початку позитивного класу — момент акумуляції OI, а не ціновий зрив. Підтверджено академічними дослідженнями pump-and-dump, які вручну зсували лейбл до 120 секунд раніше офіційного сигналу, оскільки реальний рух починається до публічного оголошення — той самий ефект, що на AKE-скріні.

Вирішено: горизонт вікна ознак перед подією — останні дві години даних перед кожним прогнозованим моментом.

Конкретний список тікерів та дат для v1-датасету — потрібно зафіксувати п'ять-десять або більше відомих пампів за останні один-два тижні.

Вирішено: Фаза 2 формалізована окремим розділом вище — включає і rush orders, і bid/ask imbalance з одного live-collector процесу. Питання про паралельність з v1 залишається відкритим: почати одразу чи після підтвердження моделі на v1.